

D A T A E N G I N E E R

Portfolio de Projets

Formation Data Engineer · OpenClassrooms

12 Projets

Python · SQL · NoSQL

Cloud AWS

ETL · ML · RAG



Sommaire

01

Analyse de données & exploration

Projet 2

02

Bases de données relationnelles & qualité

Projets 3 & 4

03

Stockage NoSQL & architecture distribuée

Projets 5 & 7

04

Pipelines & orchestration

Projet 10

05

Cloud & infrastructure AWS

Projet 8

06

Traitement de flux & temps réel

Projet 9

07

Machine Learning & déploiement

Projet 6

08

Pipeline ETL complet & monitoring

Projet 12

09

IA générative & RAG

Projet 11

10

Gestion de projet & architecture cloud

Projet 13

01

Analyse de données & exploration

Projet 2 — Expansion internationale

Projet 2 — Analyse de marché pour une expansion internationale

Problème résolu

Une entreprise souhaite identifier les pays les plus attractifs pour une expansion internationale. Les données mondiales de la Banque Mondiale sont exploitées selon quatre axes : démographie (15–24 ans), économie (revenus), éducation (taux de scolarisation) et numérique (accès à Internet).

Technologies

Python · Pandas · NumPy · Matplotlib · Seaborn · pycountry · Jupyter Lab · Poetry

Compétences démontrées

- Exploration et nettoyage de données multi-fichiers CSV (5 fichiers EdStats)
- Sélection et normalisation d'indicateurs statistiques sur une période temporelle
- Analyse de corrélations entre variables hétérogènes
- Production de classements et recommandations stratégiques basées sur les données

02

Bases de données relationnelles & qualité des données

Projets 3 & 4 — Immobilier & Distribution

Projet 3 — Analyse du marché immobilier français

Problème résolu

Une agence immobilière souhaite analyser le marché résidentiel français en 2020 à partir de données publiques brutes. L'objectif est de construire une base de données relationnelle et d'en extraire des indicateurs clés via SQL (prix au m², volumes de ventes, évolution trimestrielle).

Technologies

Python · Pandas · Jupyter Notebook · PostgreSQL · SQL · PgAdmin · PlantUML · Excel

Compétences démontrées

- Conception d'un modèle conceptuel de données (MCD) et traduction en schéma relationnel SQL
- Nettoyage et préparation de données brutes multi-sources en Python
- Écriture de requêtes SQL analytiques avancées (agrégations, jointures, classements)
- Réponse à des besoins métier concrets via des indicateurs mesurables

Projet 4 — Analyse des ventes et audit de données

Problème résolu

Une enseigne de grande distribution dispose de données brutes hétérogènes (transactions, catalogue produits, clients, employés, logs). La mission est d'auditer la qualité de ces données, d'identifier les anomalies et de produire des analyses de ventes.

Technologies

PostgreSQL · SQL · Python · Pandas · Jupyter Notebook · Excel

Compétences démontrées

- Audit de qualité des données : détection de doublons, incohérences de prix, tickets multi-journées
- Alimentation d'une base de données relationnelle à partir de fichiers hétérogènes
- Analyse des ventes : chiffre d'affaires journalier, top clients, répartition par employé
- Investigation et quantification des anomalies via le journal de logs

03

Stockage NoSQL & architecture distribuée

Projets 5 & 7 — Migration MongoDB & Airbnb

Projet 5 — Migration CSV vers MongoDB avec Docker

Problème résolu

Migration d'un dataset CSV (données de santé) vers une base de données MongoDB conteneurisée sous Docker. L'objectif est d'automatiser l'intégration des données et de documenter le processus de bout en bout.

Technologies

Python · Pandas · PyMongo · MongoDB · Docker · Docker Compose

Compétences démontrées

- Conception d'une architecture conteneurisée avec Docker Compose
- Écriture d'un script d'intégration de données CSV → MongoDB
- Documentation technique d'un processus de migration de données

Projet 7 — Conception d'une architecture NoSQL pour Airbnb

Problème résolu

Suite à un crash de base de données, les données Airbnb (Paris et Lyon) doivent être restaurées depuis une sauvegarde et réintégrées dans une architecture MongoDB repensée pour garantir la haute disponibilité et la scalabilité.

Technologies

MongoDB · Docker · Docker Compose · Python · Pandas · PyMongo · Polars · MongoDB Compass · mongosh

Compétences démontrées

- Conception et comparaison de trois architectures MongoDB : standalone, replica set, cluster shardé
- Restauration et import de données depuis une sauvegarde CSV
- Écriture de requêtes d'agrégation MongoDB et analyses Polars
- Garantie de haute disponibilité (replica set) et scalabilité horizontale (sharding)

04

Pipelines de données & orchestration

Projet 10 — Workflow Kestra pour vins

Projet 10 — Workflow d'orchestration Kestra pour la réconciliation de données vins

Problème résolu

Un vendeur de vins en ligne dispose de données issues de trois sources distinctes (ERP, site e-commerce, table de liaison) qui doivent être consolidées mensuellement pour calculer le chiffre d'affaires, détecter les incohérences de stock et identifier les produits premium.

Technologies

Kestra · Python · Pandas · NumPy · DuckDB · SQL

Compétences démontrées

- Conception d'un workflow d'orchestration planifié (cron mensuel) avec Kestra
- Fusion de données multi-sources via jointures SQL (DuckDB) et Python (Pandas)
- Analyse statistique (z-score) pour la classification de produits
- Reporting structuré : exports CSV et Excel multi-onglets
- Contrôles de cohérence automatisés et gestion des exceptions

05

Cloud & infrastructure AWS

Projet 8 — Pipeline météorologique GreenCorp

Projet 8 — Pipeline de collecte et de stockage de données météorologiques

Problème résolu

GreenCorp a besoin de données météorologiques fiables et harmonisées pour alimenter ses analyses. Le pipeline extrait les données depuis des APIs météorologiques, les transforme et les charge dans MongoDB, d'abord en local puis déployé sur AWS.

Technologies

Airbyte · Python (Pandas, PyMongo, Polars) · MongoDB · Docker · Docker Compose · JSONL · AWS (EC2, DocumentDB, S3)

Compétences démontrées

- Orchestration de l'extraction de données via Airbyte (APIs météo → S3)
- Transformation et harmonisation de données hétérogènes (unités, formats, langues)
- Script de contrôle qualité automatisé (types, valeurs nulles, coordonnées, horodatages)
- Déploiement cloud AWS : EC2, DocumentDB (cluster avec replica), S3
- Monitoring et reporting de l'infrastructure AWS

06

Traitement de flux & données temps réel

Projet 9 — Pipeline Kafka & PySpark

Projet 9 — Pipeline d'analyse de tickets avec Kafka et PySpark

Problème résolu

Des tickets clients doivent être produits en flux continu, analysés et distribués automatiquement vers les équipes de support adaptées (incident, support général, produit) en fonction de leur contenu.

Technologies

Python · Redpanda (Kafka) · PySpark · Docker · Docker Compose · Parquet · JSON

Compétences démontrées

- Conception d'un pipeline de streaming end-to-end : producteur → broker Kafka → consommateur PySpark
- Analyse et enrichissement de données en temps réel (analyse de mots-clés, statistiques par type)
- Distribution automatique des messages vers des topics Kafka par équipe
- Persistance des résultats en formats Parquet et JSON
- Monitoring temps réel via la console Redpanda

07

Machine Learning & déploiement de modèle

Projet 6 — Prédiction énergétique Seattle

Projet 6 — Prédiction de la consommation énergétique des bâtiments (Seattle)

Problème résolu

La ville de Seattle impose aux propriétaires de bâtiments non résidentiels de déclarer leur consommation énergétique. L'objectif est de prédire cette consommation à partir des caractéristiques structurelles des bâtiments et de déployer le modèle sous forme d'API REST conteneurisée.

Technologies

Python · Pandas · NumPy · Matplotlib · Seaborn · Scikit-learn (LinearRegression, SVR, RandomForest, GridSearchCV) · BentoML · Pydantic · Docker

Compétences démontrées

- Analyse exploratoire et feature engineering (ancienneté, ratios de surface, etc.)
- Entraînement et comparaison de modèles de régression supervisée
- Optimisation des hyperparamètres via GridSearchCV
- Déploiement d'un modèle ML sous forme d'API REST avec BentoML
- Conteneurisation du service de prédiction avec Docker

08

Pipeline ETL complet & monitoring

Projet 12 — Pipeline RH avec Prometheus & Grafana

Projet 12 — Pipeline ETL RH avec monitoring et notifications

Problème résolu

Une entreprise souhaite automatiser le traitement de ses données RH pour calculer des primes de mobilité durable (mode de déplacement + distance géocodée) et des jours de bien-être (activité physique enregistrée), avec supervision en temps réel.

Technologies

Python · Pandas · SQLAlchemy · psycopg2 · PostgreSQL · PgAdmin · Geopy/Nominatim · Mimesis · Slack SDK · Prometheus · Grafana · Node Exporter · cAdvisor · Postgres Exporter · Power BI · Docker · Docker Compose

Compétences démontrées

- Conception et déploiement d'un pipeline ETL complet automatisé (cycle 24h)
- Géocodage d'adresses pour le calcul de distances réelles domicile-travail
- Architecture multi-conteneurs Docker avec séparation des responsabilités
- Monitoring de pipeline en temps réel (Prometheus + Grafana)
- Notifications automatiques via Slack à chaque événement métier
- Visualisation des résultats dans un tableau de bord Power BI

09

IA générative & RAG

Projet 11 — Chatbot événements culturels

Projet 11 — Pipeline RAG pour la recommandation d'événements culturels

Problème résolu

Permettre à des utilisateurs d'interroger en langage naturel les événements publics à venir en France (collectés via l'API OpenAgenda), grâce à un système de recherche vectorielle et un chatbot propulsé par un LLM local.

Technologies

Python · OpenAgenda API · FAISS · Ollama · Mistral-Nemo (LLM) · pytest

Compétences démontrées

- Collecte et nettoyage de données via API REST (OpenAgenda)
- Création et gestion d'un index de recherche vectorielle (FAISS)
- Conception d'un pipeline RAG (Retrieval-Augmented Generation) de bout en bout
- Intégration d'un LLM local (Mistral-Nemo via Ollama) avec prompt engineering
- Tests unitaires et post-traitement automatisés

10

Gestion de projet & architecture cloud

Projet 13 — Mission freelance Puls-Events (POC → MVP)

Projet 13 — Rapport de gestion de projet : chatbot RAG POC → MVP (Puls-Events)

Problème résolu

En tant qu'ingénieur data freelance, accompagner l'entreprise Puls-Events dans la transformation de son chatbot RAG (POC validé) vers un MVP industrialisable. Le chatbot permet de rechercher des événements culturels en langage naturel via FAISS + LLM (Ollama).

Technologies

Python · LangChain · FAISS · Ollama (Mistral) · OpenAgenda API · AWS (architecture cible : compute, stockage, réseau) · Prometheus · Grafana

Compétences démontrées


- Analyse des besoins utilisateurs et définition des cas d'usage (utilisateurs occasionnels vs réguliers)
- Rédaction d'un macro backlog fonctionnel avec estimation par indice de complexité (Must have / Nice to have)
- Élaboration d'un macro planning et estimation des charges en jours/TJM
- Veille technique et comparaison cloud providers (AWS, Azure, GCP) — choix justifié d'AWS
- Conception d'une architecture cloud scalable (backend API, pipeline RAG, ingestion, base vectorielle, LLM)
- Estimation des coûts build et OPEX avec leviers d'optimisation budgétaire

Récapitulatif des technologies

Catégorie	Technologies
Langages	Python · SQL
Analyse de données	Pandas · NumPy · Polars · Matplotlib · Seaborn
Bases relationnelles	PostgreSQL · DuckDB
NoSQL	MongoDB · DocumentDB (AWS)
Orchestration	Kestra · Airbyte
Streaming	Kafka (Redpanda) · PySpark
Machine Learning	Scikit-learn · BentoML
IA générative (base de données vectorielle / LLM)	FAISS · Ollama · Mistral-Nemo
Cloud	AWS (EC2, S3, DocumentDB)
Conteneurisation	Docker · Docker Compose
Monitoring	Prometheus · Grafana · cAdvisor
Visualisation	Power BI · Apache Superset

Merci de votre attention

Portfolio complet disponible sur demande



Formation Data Engineer · OpenClassrooms